

UNIVERSITÀ POLITECNICA DELLE MARCHE
FACOLTÀ DI INGEGNERIA
Dipartimento di Ingegneria dell'Informazione
Corso di Laurea Magistrale in Ingegneria Informatica e dell'Automazione



PROGETTO DATA SCIENCE

**Serie Temporalì e Qualità dell'Aria: Analisi Statistica e Previsione
dei Ricoveri Respiratori**

Prof.

Prof. Domenico Ursino
Prof. Christopher Buratti

Candidati

La Porta Domenico
Meloccaro Lorenzo
Yassir Suarez Sanchez

ANNO ACCADEMICO 2025-2026

1	Serie Temporal	1
1.1	Introduzione	1
1.1.1	Descrizione dell'Air Quality & Health Dataset	1
1.1.2	Approccio Metodologico e Caratteristiche per il Forecasting	1
1.2	Pre-processing e Struttura del Dataset (ETL)	2
1.2.1	Definizione delle Variabili	2
1.2.2	Trasformazioni e Data Wrangling	3
1.3	Analisi Esplorativa dei Dati (EDA)	5
1.3.1	Evoluzione Cronologica delle Serie Storiche	5
1.3.2	Analisi Descrittiva Statica e Pattern Stagionali	6
1.3.3	Analisi delle Correlazioni Dinamiche e Distribuzionali	7
1.4	Analisi Qualità dell'Aria (PM2.5)	9
1.4.1	Scomposizione Classica della Serie Temporale	10
1.4.2	Test di Stazionarietà e Analisi nei Correlogrammi	11
1.4.3	Identificazione del Modello tramite Algoritmo <code>auto_arima</code>	11
1.4.4	Diagnostica Grafica dei Residui	12
1.4.5	Validazione Predittiva sul Test Set (In-Sample Forecast)	12
1.5	Modellazione e Forecasting delle Emergenze Sanitarie	13
1.5.1	Scomposizione Additiva Classica della Serie dei Ricoveri	13
1.5.2	Test di Stazionarietà e Analisi del Correlogramma	14
1.5.3	Identificazione del Modello Univariato (Modello A)	15
1.5.4	Modello unicamente teorico per il confronto (Modello B)	16
1.5.5	Validazione Predittiva e Analisi Comparativa (Modelli A, B, C)	18
1.5.6	Forecasting Futuro Fuori Campione	19

Elenco delle figure

1.1	Struttura delle feature selezionate dal dataset originale.	3
1.2	Dataset regolarizzato dopo l'operazione di resampling settimanale.	4
1.3	Verifica dell'assenza di valori nulli nel dataset finale.	5
1.4	Evoluzione temporale e confronto grafico tra i livelli di PM2.5 ($\mu g/m^3$) e il volume complessivo dei ricoveri respiratori settimanali nella regione East. . .	5
1.5	Distribuzione stagionale e boxplot dei ricoveri e dei parametri esogeni.	7
1.6	Confronto annuale delle metriche sanitarie e ambientali.	7
1.7	Analisi dei lag temporali (t, t-1, t-2) per la concentrazione di PM2.5 rispetto ai ricoveri respiratori.	8
1.8	Scatter plot condizionali della Temperatura ai lag 0, 1 e 2 rispetto al target sanitario.	8
1.9	Funzioni di Cross-Correlazione (CCF) con intervalli di confidenza al 95%: PM2.5 vs Ricoveri (sinistra) e Temperatura vs Ricoveri (destra).	9
1.10	Istogrammi di frequenza e curve KDE per le distribuzioni originali di Ricoveri, PM2.5 e Temperatura.	9
1.11	Scomposizione additiva classica della serie storica settimanale del PM2.5 nella regione East.	10
1.12	Funzioni di autocorrelazione totale (ACF) e parziale (PACF) per la serie stazionaria in livello del PM2.5.	11
1.13	Grafici accademici di diagnostica dei residui del modello ARIMA(0,0,0) stimato sulla serie del PM2.5.	12
1.14	Validazione predittiva in-sample del modello ARIMA(0,0,0) sul test set rispetto ai valori reali del PM2.5.	13
1.15	Scomposizione additiva classica della serie storica dei ricoveri ospedalieri settimanali.	14
1.16	Funzioni di autocorrelazione totale (ACF) e parziale (PACF) per la serie dei ricoveri ospedalieri.	15
1.17	Grafici di diagnostica dei residui del modello univariato ottimale ARIMA(2, 1, 1).	16
1.18	Grafici di diagnostica statistica dei residui per il modello teorico vincolato SARIMA(2,1,0) $\times$ (1,1,0) ₅₂	17
1.19	Confronto grafico sul test set tra i ricoveri reali osservati e le traiettorie predittive dei modelli A, B e C.	18
1.20	Proiezioni di forecasting futuro fuori campione (orizzonte a 4 settimane, 9–30 gennaio 2022) per i modelli univariati e multivariati.	20

Elenco delle tabelle

1.1	Tabella comparativa delle metriche di performance sul test set.	19
-----	---	----

1.1 Introduzione

Il presente lavoro si inserisce nel contesto dello studio dell'impatto dell'inquinamento atmosferico sulla salute pubblica, un'area in cui la sinergia tra data science ed epidemiologia risulta cruciale per la pianificazione sanitaria. L'obiettivo principale è la modellazione e il *forecasting* a breve termine dei ricoveri ospedalieri settimanali per cause respiratorie, analizzando come le fluttuazioni dei principali inquinanti atmosferici e delle condizioni meteorologiche anticipino i picchi di affluenza nelle strutture sanitarie.

1.1.1 Descrizione dell'Air Quality & Health Dataset

Il dataset utilizzato è l'*Air Quality & Health Dataset*, una raccolta di dati concepita per rappresentare le relazioni temporali tra l'inquinamento atmosferico e i relativi impatti sanitari. La sua adozione è giustificata dalla struttura intrinseca di **serie temporale multivariata**, che permette di studiare l'evoluzione congiunta di più variabili lungo un intervallo temporale esteso, compreso tra il 2020 e il 2022.

Si evidenzia, tuttavia, che il dataset non deriva direttamente da osservazioni empiriche, bensì è stato generato artificialmente (dati sintetici). Essi sono stati costruiti a partire da modelli e distribuzioni basati su dati reali, al fine di preservarne la plausibilità statistica e la coerenza con i fenomeni epidemiologici di riferimento. Per ragioni di consistenza e specificità dell'analisi, il dominio dell'indagine è stato circoscritto alla sola regione geografica denominata **East**.

1.1.2 Approccio Metodologico e Caratteristiche per il Forecasting

Il dataset originale presenta una struttura teoricamente giornaliera ma caratterizzata da una non-uniformità del campionamento, con la presenza di diversi giorni mancanti all'interno delle settimane osservate. In ambito di *Time Series Forecasting*, l'assenza di dati su base giornaliera impedirebbe l'applicazione diretta dei classici modelli stocastici (quali SARIMA) o richiederebbe complessi algoritmi di imputazione artificiale, con il rischio di introdurre bias sistematici.

Con 635 osservazioni giornaliere distribuite su circa 730 giorni, la serie presenta mediamente meno di un'osservazione al giorno. Usare la serie grezza a frequenza giornaliera

avrebbe comportato tre problemi strutturali: (i) SARIMA richiede una serie equispaziata, e l'imputazione di circa 570 valori mancanti avrebbe introdotto bias sistematici appresi dal modello al posto dei pattern reali; (ii) i dati sanitari giornalieri risentono di effetti calendario puri (riduzione delle ammissioni nel fine settimana per ragioni amministrative, non epidemiologiche), rumore che l'aggregazione a 7 giorni elimina; (iii) con frequenza giornaliera la stagionalità annua sarebbe a $s = 365$, richiedendo almeno $2 \times 365 = 730$ osservazioni per la stima affidabile dei parametri stagionali, soglia non raggiunta dal dataset.

Per ovviare a tale limitazione e garantire la robustezza dell'analisi, si è configurato un processo di **resampling settimanale** (*weekly resampling*). Questa scelta metodologica si rivela ottimale per tre ragioni fondamentali:

1. **Mitigazione del dato mancante:** L'aggregazione tramite operatore di media per le variabili ambientali e di sommatoria per i ricoveri permette di stabilizzare la metrica settimanale, rendendo irrilevante l'assenza sporadica di singoli record giornalieri. La somma è preferita alla media per i ricoveri perché quantifica il carico ospedaliero complessivo settimanale, grandezza di interesse diretto per la pianificazione sanitaria; la media annullerebbe invece l'informazione sul volume totale.
2. **Abbattimento del rumore logistico:** A livello giornaliero, i dati sanitari risentono fortemente di dinamiche di calendario (effetto weekend o ritardi di registrazione). L'aggregazione a 7 giorni elimina tale rumore, isolando il reale andamento epidemiologico.
3. **Regolarizzazione della serie:** Riducendo la variabilità stocastica ad alta frequenza, si favorisce una migliore convergenza degli algoritmi di fit nelle fasi successive di modellazione. Con $s = 52$, il dataset di 105 settimane supera la soglia minima di $2 \times 52 = 104$ osservazioni raccomandata per la stima dei parametri stagionali SARIMA.

1.2 Pre-processing e Struttura del Dataset (ETL)

Il dataset oggetto dello studio è composto originariamente da 26 variabili e 3.000 osservazioni complessive. Al fine di isolare le dinamiche strettamente correlate all'interazione tra inquinanti atmosferici e salute pubblica, è stata condotta una fase preliminare di *feature selection*. Tale processo ha permesso di circoscrivere l'analisi a 9 variabili chiave, riducendo la dimensionalità dello spazio delle feature e ottimizzando il carico computazionale (si veda la struttura in Fig. 1.1).

L'analisi iniziale sulla qualità del dato evidenzia che, sebbene le osservazioni fornite nel file non presentino record nulli (Non-Null Count pari al 100% per ogni colonna), la serie storica originale a livello giornaliero mostra un campionamento non uniforme con diverse lacune temporali (giorni mancanti all'interno delle settimane). Di conseguenza, il processo di ETL ha dovuto integrare una strategia di regolarizzazione temporale per garantire l'idoneità della serie alla modellazione predittiva.

1.2.1 Definizione delle Variabili

Le variabili selezionate sono state classificate in quattro domini funzionali:

Dimensione Temporale e Geografica Fornisce il framework per la strutturazione dei dati come serie storica:

- **date** (`datetime`): Variabile convertita in formato temporale per abilitare l'ordinamento sequenziale e l'analisi della stagionalità.

- **region** (category): Identificatore geografico. Per questo studio, l'analisi è stata focalizzata sulla sola regione 'East', selezionata come area di studio a causa della rilevanza dei pattern osservati.

Indicatori della Qualità dell'Aria (Feature Esogene) Parametri che quantificano l'esposizione ambientale:

- **PM2.5, NO2, O3**: Concentrazioni di inquinanti misurate in $\mu g/m^3$. Il focus principale della modellazione multivariata sarà incentrato sulla dinamica del PM2.5.

Variabili Meteorologiche Fattori che influenzano la dispersione e il ristagno degli inquinanti:

- **temperature (°C), humidity (%), wind_speed (m/s)**: Variabili meteorologiche rilevate localmente, utilizzate per tenere conto delle condizioni atmosferiche nei modelli multivariati.

Target Sanitario (Variabile Dipendente) L'output del sistema di forecasting:

- **respiratory_admissions** (int): Numero di ricoveri ospedalieri giornalieri per patologie respiratorie. Rappresenta la variabile target del modello.

Data columns (total 9 columns):

#	Column	Non-Null Count	Dtype
0	date	3000 non-null	object
1	region	3000 non-null	object
2	PM2.5	3000 non-null	float64
3	NO2	3000 non-null	float64
4	O3	3000 non-null	float64
5	temperature	3000 non-null	float64
6	humidity	3000 non-null	float64
7	wind_speed	3000 non-null	float64
8	respiratory_admissions	3000 non-null	int64

Figura 1.1: Struttura delle feature selezionate dal dataset originale.

1.2.2 Trasformazioni e Data Wrangling

Per trasformare il dato grezzo in una serie temporale equispaziata e idonea alla modellazione stocastica, sono state applicate le seguenti procedure nel notebook di analisi:

1. **Filtraggio e Ordinamento:** Il dataset è stato ridotto alla sola regione 'East' (~635 record giornalieri effettivi) e ordinato cronologicamente lungo l'asse temporale per preservare la sequenzialità dei lag.

2. **Aggregazione Temporale e Resampling Settimanale (Downsampling):** Per sanare la non-uniformità del campionamento giornaliero e abbattere il rumore ad alta frequenza dovuto a fluttuazioni amministrative o logistiche, la serie è stata aggregata su base settimanale (frequenza 'W'). La scelta delle funzioni di aggregazione ha seguito logiche matematiche differenziate per dominio:

- Per le variabili di qualità dell'aria (PM2.5) e meteorologiche (temperature), è stata applicata la **media settimanale** (mean), in modo da catturare l'esposizione cronica o media della popolazione in quel framework temporale.
- Per la variabile target `respiratory_admissions`, è stata applicata la **sommatoria settimanale** (sum), al fine di quantificare l'impatto e il carico di ospedalizzazione complessivo gravante sulle strutture sanitarie nell'arco dei 7 giorni. La somma è preferita alla media perché è la grandezza rilevante per la pianificazione dei posti letto e del personale medico.

Tale procedura ha permesso di isolare i trend di medio-lungo periodo, generando una serie temporale finale perfettamente regolare composta da $N = 105$ settimane osservate, priva di lacune e matematicamente pronta per l'algoritmo di fit dei modelli SARIMA.

L'output di questa fase ETL è un dataset regolarizzato e pronto per le successive fasi di analisi esplorativa (EDA).

Dataset settimanale pronto e allineato:

	PM2.5	NO2	O3	temperature	humidity \
date					
2020-01-05	59.384035	36.761954	31.036800	26.866985	52.120856
2020-01-12	57.604828	44.890266	33.386451	24.287743	52.805481
2020-01-19	56.847925	33.771576	32.032120	21.802331	40.455749
2020-01-26	62.029037	43.802169	30.755770	22.198627	57.556851
2020-02-02	59.843503	35.706730	32.199352	26.193452	50.902530

	wind_speed	respiratory_admissions
date		
2020-01-05	5.320074	41
2020-01-12	9.054286	125
2020-01-19	5.082848	67
2020-01-26	6.129686	84
2020-02-02	6.555219	88

Figura 1.2: Dataset regolarizzato dopo l'operazione di resampling settimanale.

Infine, come controllo di robustezza del processo ETL, è stata verificata l'assenza di record nulli o duplicati a seguito dell'aggregazione. Come evidenziato dall'output di Figura 1.3, l'allineamento temporale ha prodotto una matrice di dati satura e priva di mancate comunicazioni.


```

PM2.5      0
NO2        0
O3         0
temperature 0
humidity    0
wind_speed  0
respiratory_admissions 0
dtype: int64

```

Figura 1.3: Verifica dell'assenza di valori nulli nel dataset finale.

1.3 Analisi Esplorativa dei Dati (EDA)

L'analisi esplorativa è stata finalizzata alla comprensione delle proprietà statistiche intrinseche delle serie storiche, con particolare attenzione alla stazionarietà, alla stagionalità e alla relazione dinamica cross-correlata tra inquinanti atmosferici e ospedalizzazioni.

1.3.1 Evoluzione Cronologica delle Serie Storiche

Prima di procedere alle analisi statiche e all'estrazione dei descrittori stagionali, è stata mappata l'evoluzione temporale congiunta delle due variabili cardinali lungo l'intero orizzonte temporale coperto dal dataset (2020–2022). Questa visualizzazione macroscopica primaria, riportata in Figura 1.4, permette di valutare l'andamento simultaneo del predittore esogeno PM2.5 (rappresentato sull'asse delle ordinate sinistro) e del target sanitario respiratory_admissions (mappato sull'asse delle ordinate destro).




Figura 1.4: Evoluzione temporale e confronto grafico tra i livelli di PM2.5 ($\mu\text{g}/\text{m}^3$) e il volume complessivo dei ricoveri respiratori settimanali nella regione East.

L'ispezione visiva del grafico lineare integrato evidenzia un comportamento stocastico ad alta variabilità e frequenza. Non si ravvisano macro-trend deterministici lineari o derive monotone unidirezionali di lungo periodo; al contrario, entrambe le serie oscillano all'interno di intervalli costanti, manifestando comportamenti ciclici e ondulazioni ripetitive che suggeriscono una forte componente stocastica e la necessità di successive verifiche formali di stazionarietà tramite test statistici dedicati. La correlazione di Pearson istantanea (lag 0) tra

PM2.5 e ricoveri risulta $r = +0.042$ ($p = 0.671$), confermando visivamente l'assenza di una relazione lineare diretta tra le due serie.

1.3.2 Analisi Descrittiva Statica e Pattern Stagionali

L'esplorazione quantitativa del target sanitario aggregato `respiratory_admissions` e delle principali variabili esogene ambientali (PM2.5, `temperature`) ha permesso di mappare il comportamento e la consistenza della serie storica lungo i cicli stagionali e annuali. I risultati emersi dall'estrazione delle statistiche descrittive evidenziano dinamiche di forte interesse modellistico:

- **Dinamica dei Ricoveri Settimanali:** Il carico ospedaliero manifesta una chiara oscillazione stagionale sia in media che in termini di scenari estremi. La stagione estiva (*Summer*) registra la media settimanale più elevata ($\mu = 63.65$ ricoveri/settimana), seguita a stretto giro dall'inverno (*Winter*, $\mu = 62.69$). Quest'ultimo, tuttavia, presenta il quadro di acuzie più critico, facendo registrare il picco massimo assoluto dell'intera serie storica pari a **125 ricoveri in una singola settimana** e una varianza altissima ($\sigma^2 = 709.74$). Al contrario, la primavera (*Spring*) si configura come il periodo a minore impatto relativo, con una media di 53.37 ricoveri e un picco massimo contenuto a 81.
- **Comportamento del PM2.5:** A differenza delle serie storiche empiriche temperate, dove il particolato subisce forti abbattimenti estivi, nel presente dataset la concentrazione media di PM2.5 si mantiene eccezionalmente stabile e critica in tutte le stagioni, oscillando in un range ristretto compreso tra $58.48 \mu\text{g}/\text{m}^3$ (in estate) e $60.36 \mu\text{g}/\text{m}^3$ (in primavera). Si riscontra però una forte instabilità climatica interna durante la primavera e l'inverno, stagioni in cui la varianza del particolato sale rispettivamente a 58.31 e 57.42, spingendo i picchi di inquinamento acuto fino a massimi di $77.95 \mu\text{g}/\text{m}^3$ e $81.35 \mu\text{g}/\text{m}^3$.
- **Analisi Annuale delle Tendenze:** Il confronto interannuale tra il 2020 ($\mu_{\text{ricoveri}} = 65.04$, $\sigma^2 = 502.35$) e il 2021 ($\mu_{\text{ricoveri}} = 55.40$, $\sigma^2 = 584.99$) mostra una leggera riduzione del volume medio, accompagnata tuttavia da una maggiore instabilità interna e da picchi più estremi nel 2021. Tale dinamica specchia parzialmente il comportamento del PM2.5, che sperimenta un netto incremento della varianza nel corso del secondo anno (da 28.48 a 62.08), indicando un regime ambientale caratterizzato da ondate acute alternate a repentine conversioni. Il 2022 è rappresentato da una sola settimana di dati e non è statisticamente rappresentativo.

Nota metodologica sulla Temperatura e Limiti del Dataset: Un'evidenza fondamentale emersa dall'analisi statistica riguarda la variabile `temperature`. Essa presenta una media quasi identica e livellata in tutte le stagioni dell'anno, attestandosi costantemente a circa 25°C ($\mu_{\text{Autumn}} = 25.01^\circ\text{C}$, $\mu_{\text{Spring}} = 24.92^\circ\text{C}$, $\mu_{\text{Summer}} = 24.51^\circ\text{C}$, $\mu_{\text{Winter}} = 25.31^\circ\text{C}$).

Questo comportamento non rispecchia una transizione stagionale climatica reale ed è riconducibile alla natura controllata della generazione sintetica del dato. Ai fini della modellazione autoregressiva, ciò implica che le componenti deterministiche stagionali della serie dei ricoveri non potranno essere spiegate linearmente dal profilo termico medio. Tale limite è confermato dall'analisi di correlazione: la correlazione di Pearson tra temperatura e ricoveri è $r = +0.010$ ($p = 0.919$), statisticamente non significativa, e analoga non significatività si osserva per tutte le variabili ambientali disponibili (cfr. Sezione 1.3.3).

Stagione	Variabile	mean	var	min	max
Autumn	NO2	40.68	14.75	35.03	50.66
	O3	30.30	13.79	23.30	38.21
	PM2.5	59.07	42.41	46.33	72.69
	humidity	52.85	76.94	36.21	69.45
	respiratory_admissions	59.96	706.76	19.00	114.00
	temperature	25.01	5.85	19.64	30.00
	wind_speed	7.41	2.36	3.87	9.63
Spring	NO2	39.21	16.65	31.64	45.68
	O3	31.83	13.70	25.90	40.11
	PM2.5	60.36	58.31	46.42	81.35
	humidity	57.63	89.44	36.32	72.51
	respiratory_admissions	53.37	272.32	24.00	81.00
	temperature	24.92	8.86	15.36	30.84
	wind_speed	7.50	3.10	4.05	11.82
Summer	NO2	40.66	22.88	30.64	52.11
	O3	30.48	13.41	25.12	38.79
	PM2.5	58.48	35.85	46.31	70.67
	humidity	54.05	59.27	37.78	67.52
	respiratory_admissions	63.65	604.08	31.00	110.00
	temperature	24.51	1.89	21.70	26.82
	wind_speed	7.52	3.74	3.54	12.79
Winter	NO2	38.54	17.04	25.21	44.89
	O3	30.84	6.45	26.08	35.40
	PM2.5	59.93	57.42	43.47	77.95
	humidity	54.68	77.04	26.75	68.90
	respiratory_admissions	62.69	709.74	18.00	125.00
	temperature	25.31	7.37	21.08	33.30
	wind_speed	7.51	4.14	4.49	11.50

Figura 1.5: Distribuzione stagionale e boxplot dei ricoveri e dei parametri esogeni.

```

=== Statistiche descrittive per ANNO ===

```

year		mean	var	min	max
2020	NO2	39.86	13.23	32.42	50.66
	O3	30.92	7.22	25.11	36.46
	PM2.5	59.22	28.48	48.21	72.69
	humidity	55.01	73.85	36.21	72.51
	respiratory_admissions	65.04	502.35	19.00	125.00
	temperature	25.14	3.08	21.39	29.07
	wind_speed	7.32	3.83	3.54	12.79
2021	NO2	39.67	23.80	25.21	52.11
	O3	30.82	16.99	23.30	40.11
	PM2.5	59.36	62.08	43.47	81.35
	humidity	55.19	67.13	37.78	70.75
	respiratory_admissions	55.40	584.99	18.00	120.00
	temperature	24.58	7.46	15.36	30.84
	wind_speed	7.60	2.61	4.49	11.82
2022	NO2	39.76	NaN	39.76	39.76
	O3	30.99	NaN	30.99	30.99
	PM2.5	77.95	NaN	77.95	77.95
	humidity	26.75	NaN	26.75	26.75
	respiratory_admissions	22.00	NaN	22.00	22.00
	temperature	33.30	NaN	33.30	33.30
	wind_speed	9.96	NaN	9.96	9.96

NOTA: 2022 ha una sola settimana di dati + var=NaN e statistiche non rappresentative.

Figura 1.6: Confronto annuale delle metriche sanitarie e ambientali.

1.3.3 Analisi delle Correlazioni Dinamiche e Distribuzionali

L'indagine esplorativa è stata approfondita attraverso lo studio della struttura dei ritardi (*lag analysis*), del calcolo della funzione di cross-correlazione, dell'analisi della matrice di correlazione di Pearson e della forma distributiva delle serie storiche originali, elementi determinanti per valutare la presenza di componenti autoregressive o relazioni lineari immediate.

Matrice di Correlazione di Pearson L'analisi sistematica delle correlazioni lineari tra tutte le variabili ambientali disponibili e il target sanitario ha prodotto un risultato di rilievo metodologico: nessuna variabile esogena presenta una correlazione statisticamente significativa con i ricoveri respiratori. I valori di Pearson e i relativi p-value sono riportati in ordine decrescente di $|r|$: wind_speed ($r = -0.076$, $p = 0.443$, n.s.), PM2.5 ($r = +0.042$, $p = 0.671$, n.s.), humidity ($r = -0.035$, $p = 0.719$, n.s.), NO2 ($r = -0.028$, $p = 0.778$, n.s.), O3 ($r = +0.024$, $p = 0.809$, n.s.), temperature ($r = +0.010$, $p = 0.919$, n.s.). Questo risultato, coerente con la natura sintetica del dataset, anticipa i limiti della modellazione multivariata e motiva l'analisi di lag e cross-correlazione descritta di seguito.

Analisi dei Lag e Accoppiamento Esogeno Attraverso l'utilizzo di *scatter plot* condizionali con ritardi temporali (t , $t - 1$, $t - 2$), è stata indagata la potenziale relazione predittiva ritardata tra i fattori ambientali e il target sanitario:

- **Analisi di Indipendenza del PM2.5:** L'ispezione visiva dei lag relativi al PM2.5 (Fig. 1.7) evidenzia una nuvola di punti isotropa e ad alta dispersione, che si mantiene pressoché invariata dal Lag 0 fino al Lag 2. Tale comportamento indica l'assenza di una correlazione lineare semplice o immediata tra le singole fluttuazioni settimanali del particolato e i ricoveri, coerentemente con i valori di Pearson non significativi osservati nella matrice di correlazione.

- **Struttura della Temperatura:** Gli scatter plot della variabile `temperature` (Fig. 1.8) mostrano una caratteristica distribuzione discretizzata a bande verticali confinata tra i 20°C e i 30°C. La persistenza di questa configurazione geometrica lungo tutti i lag considerati conferma la forte stazionarietà deterministica e la ridotta variabilità dinamica di questo parametro all'interno del dataset.




Figura 1.7: Analisi dei lag temporali (t, t-1, t-2) per la concentrazione di PM2.5 rispetto ai ricoveri respiratori.




Figura 1.8: Scatter plot condizionali della Temperatura ai lag 0, 1 e 2 rispetto al target sanitario.

Analisi della Cross-Correlazione Formale (CCF) Per validare matematicamente le relazioni di dipendenza ritardata accennate dagli scatter plot, è stata stimata la Funzione di Cross-Correlazione (CCF) tra i predittori ambientali e il target sanitario, i cui grafici a impulsi sono riportati in Figura 1.9. Le linee tratteggiate orizzontali in rosso delimitano l'intervallo di confidenza statistica al 95% (± 0.19).

- **CCF PM2.5 → Ricoveri:** Il correlogramma conferma quantitativamente l'indipendenza lineare di breve termine: i coefficienti associati ai lag più vicini si posizionano stabilmente all'interno della banda di rumore bianco. L'unico elemento parzialmente rilevante si registra come un impulso negativo isolato in corrispondenza del Lag 11, dinamica legata alle fluttuazioni di medio periodo intrinseche alla generazione sintetica del dataset, che esclude legami causali diretti e immediati.
- **CCF Temperatura → Ricoveri:** Il profilo esibisce un picco di correlazione negativa statisticamente significativo concentrato sul Lag 12. Tale evidenza suggerisce la presenza di una ciclicità periodica strutturata nel modello di simulazione dei dati a circa 3 mesi di distanza temporale, ma non costituisce un legame causale interpretabile epidemiologicamente dato il comportamento artificialmente stazionario della temperatura nel dataset.




Figura 1.9: Funzioni di Cross-Correlazione (CCF) con intervalli di confidenza al 95%: PM2.5 vs Ricoveri (sinistra) e Temperatura vs Ricoveri (destra).

Analisi Distribuzionale del Profilo di Input Prima di procedere ai test di stazionarietà, è stata valutata la forma distributiva delle tre variabili principali tramite istogrammi empirici e curve di densità kernel stimata (KDE), i cui profili sono riportati in Figura 1.10.

- **Target respiratory admissions:** La variabile presenta una distribuzione unimodale e sorprendentemente simmetrica, centrata attorno al proprio valore medio. Non si riscontrano asimmetrie marcate o code pesanti a destra, indicando un regime di fluttuazione ospedaliera stabile e privo di outlier sanitari anomali nel periodo osservato.
- **Variabili Ambientali (PM2.5 e temperature):** Entrambi i predittori esogeni mostrano distribuzioni fortemente concentrate. In particolare, il profilo termico evidenzia una distribuzione quasi uniforme e ristretta, coerente con le analisi statiche precedenti, confermando la natura controllata e regolare delle serie generate.




Figura 1.10: Istogrammi di frequenza e curve KDE per le distribuzioni originali di Ricoveri, PM2.5 e Temperatura.

1.4 Analisi Qualità dell'Aria (PM2.5)

Al fine di strutturare un framework predittivo multivariato per i ricoveri ospedalieri, si rende preliminarmente necessaria la modellazione stocastica univariata della principale variabile esogena ambientale: la concentrazione settimanale di PM2.5.

1.4.1 Scomposizione Classica della Serie Temporale

Per isolare le componenti deterministiche e stocastiche che governano la dinamica del particolato fine, è stata eseguita una scomposizione classica di tipo additivo sulla serie settimanale filtrata per la regione *East* ($N = 105$). I profili estratti dall’algoritmo sono riportati in Figura 1.11.

- **Componente di Trend:** L’analisi del trend-ciclo evidenzia macro-oscillazioni sinusoidali non monotone nel lungo periodo, prive di una tendenza lineare univoca o di derivate unidirezionali. La traiettoria fluttua costantemente all’interno del range $[58.5, 61.5] \mu\text{g}/\text{m}^3$, confermando l’assenza di un trend deterministico costante.
- **Componente Stagionale:** Si rileva un’oscillazione ciclica regolare ed equispaziata con periodo fisso $s = 52$ settimane. L’ampiezza di tale scomposizione risulta tuttavia confinata entro un intervallo infinitesimale (compreso tra -0.02 e $+0.04 \mu\text{g}/\text{m}^3$), indicando come la componente stagionale annua rigida apporti un contributo quasi nullo alla varianza complessiva del fenomeno. La forza della componente stagionale stimata è pari a 0.499, da interpretare con cautela in quanto calcolata su meno di 2 cicli completi.
- **Residui Irregolari:** La componente residuale assorbe la quasi totalità della varianza della serie originale, oscillando caoticamente tra -20 e $+20 \mu\text{g}/\text{m}^3$. Tale evidenza dimostra che la dinamica del PM2.5 nel dataset sintetico è dominata da un forte moto stocastico ad alta frequenza (rumore), privo di pattern stagionali macroscopici.



Figura 1.11: Scomposizione additiva classica della serie storica settimanale del PM2.5 nella regione East.

1.4.2 Test di Stazionarietà e Analisi nei Correlogrammi

La corretta specificazione dei modelli della famiglia ARIMA richiede la verifica formale della stazionarietà statistica della serie storica per evitare fenomeni di regressione spuria.

- **Augmented Dickey-Fuller (ADF) Test:** Il test applicato sulla serie originale del PM2.5 ha restituito una statistica ADF pari a -9.019 e un conseguente p -value pari a 0.000 (inferiore a 10^{-8}). Essendo tale valore ampiamente inferiore alla soglia di significatività critica ($\alpha = 0.05$), si rifiuta categoricamente l’ipotesi nulla di presenza di radice unitaria. La serie originale risulta pertanto stazionaria in media e varianza già in livello, implicando un ordine di integrazione ottimale $d = 0$. Il confronto AIC tra configurazioni con $d = 0$ e $d = 1$ (AIC: 706.86 vs 731.23, differenza = 24.37) conferma ulteriormente la scelta $d = 0$.
- **Analisi ACF e PACF:** I correlogrammi della Funzione di Autocorrelazione (ACF) e Autocorrelazione Parziale (PACF) della serie originaria sono illustrati in Figura 1.12. Coerentemente con il test ADF, l’azzeramento dei coefficienti al di fuori delle bande di confidenza al 95% (area ombreggiata) evidenzia l’assenza di dipendenze a lungo termine o di pattern autoregressivi complessi.



Figura 1.12: Funzioni di autocorrelazione totale (ACF) e parziale (PACF) per la serie stazionaria in livello del PM2.5.

1.4.3 Identificazione del Modello tramite Algoritmo `auto_arima`

Per determinare la combinazione ottimale dei parametri stocastici, è stata implementata la procedura di ottimizzazione automatica `auto_arima` vincolata alla minimizzazione del criterio informativo di Akaike (AIC). L’algoritmo ha valutato le configurazioni nello spazio degli stati imponendo $d = 0$ e $D = 0$ in accordo con i test diagnostici.

Il modello ottimale selezionato è una struttura puramente stocastica assimilabile a un rumore bianco: un modello **ARIMA(0, 0, 0)** — equivalente a un **SARIMA(0, 0, 0) $\times$ (0, 0, 0)₅₂** — che fa registrare un valore di AIC pari a 706.856 e BIC pari a 712.164. La totale assenza di coefficienti autoregressivi ($p = 0$) o di media mobile ($q = 0$) sancisce matematicamente che la serie del PM2.5 non presenta memoria storica utile ai fini predittivi univariati, comportandosi come un processo puramente stocastico scorrelato (rumore bianco con intercetta $\hat{\mu} = 59.47 \mu\text{g}/\text{m}^3$).

La validazione è confermata dal test di Ljung-Box applicato sui residui del fit, il quale restituisce un p -value pari a 0.273 al lag 1 e 0.731 al lag 10. Essendo ampiamente superiori alla banda critica di 0.05, si accetta l’ipotesi nulla di assenza di autocorrelazione seriale nei residui.

1.4.4 Diagnostica Grafica dei Residui

L'analisi diagnostica strutturale per il modello ARIMA(0,0,0) selezionato è riportata nei quattro quadranti di Figura 1.13.




Figura 1.13: Grafici accademici di diagnostica dei residui del modello ARIMA(0,0,0) stimato sulla serie del PM2.5.

L'analisi visiva dei singoli quadranti conferma l'adeguatezza statistica del fit per quanto riguarda la struttura seriale dei residui:

- **Standardized Residuals:** Gli errori oscillano in modo omoschedastico ed isotropo all'interno della banda $[-3, +3]$ attorno alla linea dello zero, escludendo variazioni sistematiche della varianza nel tempo.
- **Histogram plus Estimated Density:** La densità empirica stimata tramite Kernel Density Estimation (KDE) approssima il profilo della densità normale teorica $\mathcal{N}(0, 1)$, pur con alcune deviazioni nelle code (Jarque-Bera: $p = 0.009$; Shapiro-Wilk: $p = 0.022$) che segnalano una lieve non-normalità dei residui. Gli intervalli di confidenza potrebbero pertanto risultare leggermente imprecisi.
- **Normal Q-Q Plot:** I quantili campionari si dispongono linearmente lungo la retta di riferimento con deviazioni moderate sulle code, coerenti con i test di normalità.
- **Correlogram (ACF):** Ad eccezione del lag 0 (pari a 1 per definizione), tutti i coefficienti di autocorrelazione per i lag successivi rimangono confinati entro le bande di confidenza, validando l'ipotesi di White Noise per la struttura seriale dei residui.

1.4.5 Validazione Predittiva sul Test Set (In-Sample Forecast)

Il dataset è stato suddiviso tramite un approccio strutturato di *Train/Test Split* (80% addestramento, $N_{train} = 84$; 20% validazione, $N_{test} = 21$). La proiezione predittiva in-sample eseguita sulle 21 settimane di test è illustrata in Figura 1.14.




Figura 1.14: Validazione predittiva in-sample del modello ARIMA(0,0,0) sul test set rispetto ai valori reali del PM2.5.

Le metriche di errore calcolate sul subset di test evidenziano le limitazioni intrinseche della serie storica:

- **Mean Absolute Error (MAE):** $5.45 \mu\text{g}/\text{m}^3$
- **Root Mean Squared Error (RMSE):** $7.46 \mu\text{g}/\text{m}^3$
- **Coefficiente di Determinazione (R^2):** -0.000

Il valore del coefficiente R^2 prossimo a zero indica che il modello predittivo non è in grado di anticipare le oscillazioni puntuali ad alta frequenza del particolato fine, appiattendosi sul valore medio storico ($\hat{\mu} = 59.50 \mu\text{g}/\text{m}^3$). Tale comportamento, graficamente esplicitato dalla retta di forecast piatta di Figura 1.14, rappresenta la risposta matematica ottimale per un processo a memoria nulla: in assenza di struttura autocorelativa, la miglior previsione è la media storica, e l'MAE di $5.45 \mu\text{g}/\text{m}^3$ rappresenta la variabilità stocastica intrinseca non riducibile della serie.

1.5 Modellazione e Forecasting delle Emergenze Sanitarie

Al fine di isolare le componenti strutturali e deterministiche che governano l'affluenza ospedaliera, la serie storica settimanale del target `respiratory_admissions` ($N = 105$) è stata analizzata attraverso un approccio incrementale, confrontando modelli stocastici univariati e configurazioni multivariate a regressori esogeni.

1.5.1 Scomposizione Additiva Classica della Serie dei Ricoveri

La serie è stata preliminarmente scissa nelle sue tre componenti fondamentali (Trend-ciclo, Stagionalità e Residuo irregolare) mediante una decomposizione classica di tipo additivo:

$$y_t = T_t + S_t + I_t \quad (1.5.1)$$

I profili generati dall'algoritmo sono riportati in Figura 1.15.




Figura 1.15: Scomposizione additiva classica della serie storica dei ricoveri ospedalieri settimanali.

- **Componente di Trend-Ciclo (T_t):** L'analisi evidenzia una traiettoria macro-oscillatoria non lineare compresa tra 56 e 64 ricoveri settimanali. L'andamento mostra fluttuazioni ondulatorie simmetriche senza esibire una deriva monotona o un trend lineare costante di lungo periodo.
- **Componente Stagionale (S_t):** Si rileva un pattern stagionale annuo ($s = 52$) speculare e rigido. L'ampiezza di oscillazione della componente legata al calendario risulta tuttavia estremamente ridotta (confinata tra -0.5 e $+1.0$ ricoveri), denotando come la sola informazione temporale deterministica sia insufficiente a spiegare la reale varianza dei picchi acuti. La forza della componente stagionale stimata è pari a 0.552, con la stessa cautela interpretativa già discussa per il PM2.5.
- **Residuo Irregolare (I_t):** La componente stocastica assorbe la frazione dominante della variabilità della serie, con oscillazioni casuali comprese nel range $[-40, +40]$. La presenza di spike isolati indica l'insorgenza di anomalie epidemiche o picchi sanitari acuti aciclici.

1.5.2 Test di Stazionarietà e Analisi del Correlogramma

La corretta identificazione dei parametri dei filtri autoregressivi impone la verifica formale delle proprietà di stazionarietà della serie storica.

- **Augmented Dickey-Fuller (ADF) Test:** Il test applicato sui ricoveri in livello ha restituito una statistica ADF pari a -5.114 e un conseguente p -value pari a 1.3×10^{-5} . Essendo ampiamente inferiore al livello di significatività standard ($\alpha = 0.05$), si rifiuta l'ipotesi nulla di radice unitaria. La serie dei ricoveri risulta stazionaria in media già in livello.

- **Analisi di ACF e PACF:** I correlogrammi della Funzione di Autocorrelazione (ACF) e Autocorrelazione Parziale (PACF) per la serie originale sono riportati in Figura 1.16. L’azzeramento quasi istantaneo dei coefficienti dopo il Lag 1 (che rimangono confinati entro le bande di confidenza al 95%) conferma visivamente la stazionarietà in livello ed esclude la presenza di forti memorie a lungo termine o di persistenti pattern stagionali autoregressivi a Lag 52.




Figura 1.16: Funzioni di autocorrelazione totale (ACF) e parziale (PACF) per la serie dei ricoveri ospedalieri.

1.5.3 Identificazione del Modello Univariato (Modello A)

Per stabilire una baseline predittiva univariata, è stato implementato l’algoritmo di ottimizzazione `auto_arima` in modalità `stepwise`. La ricerca nello spazio dei modelli, vincolata alla minimizzazione del criterio informativo di Akaike (AIC), ha selezionato come struttura ottimale un modello non stagionale **ARIMA(2, 1, 1)** — equivalente a un **SARIMA(2, 1, 1) × (0, 0, 0)₅₂** — con un AIC pari a 961.868 e BIC pari a 972.445.

La presenza di un ordine differenziato $d = 1$ potrebbe sembrare in contrasto con la stazionarietà rilevata dall’ADF. Tuttavia, il confronto sistematico dell’AIC tra le configurazioni con $d = 0$ e $d = 1$, eseguito a parità di struttura AR/MA ottimizzata, ha restituito rispettivamente $AIC = 967.33$ e $AIC = 961.87$, con una differenza di 5.46 punti a favore di $d = 1$. Tale margine, superiore alla soglia convenzionale di 2 unità, giustifica la scelta dell’operatore di differenziazione, indicando la presenza di una debole non-stazionarietà locale non catturata dal test globale ADF.

I termini stagionali non risultano significativi e sono stati esclusi dal modello ottimale, suggerendo che la struttura dei dati non presenti una componente stagionale stabile a scala annuale. La dinamica della serie è descritta da due termini autoregressivi ($ar.L1$, $ar.L2$) e da un termine di media mobile ($ma.L1$), che catturano le dipendenze di breve periodo e la propagazione degli shock.

Analisi Diagnostica dei Residui

La validazione statistica del Modello A è stata verificata tramite lo studio diagnostico a quattro quadranti dei residui, illustrato in Figura 1.17.




Figura 1.17: Grafici di diagnostica dei residui del modello univariato ottimale ARIMA(2, 1, 1).

L'analisi dei singoli moduli conferma il superamento dei vincoli statistici della modellazione lineare per quanto riguarda la struttura seriale:

- **Standardized Residuals:** Gli errori di previsione mostrano un comportamento prevalentemente omoschedastico, oscillando in modo casuale all'interno del range $[-3, +3]$ attorno alla retta dello zero, indicando stabilità della varianza.
- **Histogram plus KDE:** La funzione di densità empirica stimata approssima la distribuzione normale teorica $\mathcal{N}(0, 1)$, pur con deviazioni segnalate dai test formali (Jarque-Bera: $p = 0.003$; Shapiro-Wilk: $p = 0.003$), che indicano una lieve non-normalità dei residui. Gli intervalli di confidenza delle previsioni vanno pertanto interpretati con cautela.
- **Normal Q-Q Plot:** I quantili della serie campionaria dei residui aderiscono alla retta rossa di riferimento nella regione centrale, con deviazioni moderate sulle code coerenti con i test di normalità.
- **Correlogram (ACF):** Ad eccezione del lag nullo, tutti i coefficienti di autocorrelazione dei residui giacciono all'interno della fascia di significatività. L'assenza di spike esterni è confermata dal test formale di **Ljung-Box** che restituisce p -value pari a 0.491 al lag 10 e 0.513 al lag 20 (accettazione dell'ipotesi nulla di residui serialmente indipendenti).

1.5.4 Modello unicamente teorico per il confronto (Modello B)

Al fine di valutare la robustezza del modello univariato ottimale (Modello A) e strutturare un framework comparativo, è stato introdotto un modello alternativo con vincoli di differenziazione imposti a priori, indipendentemente dai risultati dei test di stazionarietà e dall'ottimizzazione basata su AIC.

Nello specifico, è stata considerata un'architettura stagionale **SARIMA**(2,1,0) $\times$ (1,1,0)₅₂, nella quale sono stati imposti un ordine di integrazione regolare $d = 1$ e una componente

stagionale $D = 1$ sul lag annuale $s = 52$. Tale configurazione ha l'obiettivo di esplorare l'effetto di una modellazione più vincolata sulle dinamiche della serie, imponendo una struttura differenziata più aggressiva rispetto al modello selezionato automaticamente.

Questa scelta non deriva da criteri di ottimizzazione statistica basati sulla minimizzazione dell'AIC, ma da un approccio di *stress-testing* modellistico, volto a valutare la sensibilità delle prestazioni predittive rispetto a una possibile sovrastrutturazione del processo di differenziazione. Si segnala che con soli 84 punti di training, l'imposizione di $D = 1$ a $s = 52$ lascia un numero estremamente ridotto di gradi di libertà effettivi per la stima del parametro stagionale.

Analisi Diagnostica dei Residui del Modello B

Il fit del modello è stato valutato mediante l'analisi dei residui standardizzati e dei correlogrammi degli errori, riportati in Figura 1.18. L'analisi di convergenza ha rilevato un errore standard del parametro σ^2 pari a 4876.5, segnale inequivocabile di non-convergenza del modello. I risultati del Modello B vanno pertanto interpretati con estrema cautela.




Figura 1.18: Grafici di diagnostica statistica dei residui per il modello teorico vincolato $\text{SARIMA}(2,1,0) \times (1,1,0)_{52}$.

L'analisi dei singoli quadranti evidenzia alcune criticità strutturali compatibili con la non-convergenza e l'introduzione di una differenziazione più restrittiva rispetto alla dinamica intrinseca dei dati:

- **Standardized Residuals:** Gli errori si mantengono prevalentemente entro l'intervallo $[-3, +3]$, tuttavia si osservano cluster di varianza localizzati e una lieve eterogeneità della dispersione, suggerendo una maggiore instabilità rispetto al Modello A.
- **Histogram plus KDE:** La densità empirica dei residui si discosta dalla distribuzione normale teorica $\mathcal{N}(0, 1)$, mostrando una maggiore concentrazione centrale e code leggermente più pesanti, compatibili con una perdita di informazione strutturale.
- **Normal Q-Q Plot:** Il grafico quantile-quantile evidenzia deviazioni nelle code distributive, suggerendo possibili effetti di non linearità o di over-differencing.
- **Correlogram (ACF):** La funzione di autocorrelazione dei residui mostra valori entro le bande di confidenza (Ljung-Box: $p = 0.501$ al lag 10), indicando assenza di autocorrelazione residua significativa, sebbene la non-convergenza renda inaffidabile l'interpretazione degli intervalli di confidenza.

1.5.5 Validazione Predittiva e Analisi Comparativa (Modelli A, B, C)

Per testare la reale capacità predittiva e la robustezza degli algoritmi fuori campione, il dataset è stato frazionato tramite un approccio di *Train/Test Split* strutturato (80% Training, $N_{train} = 84$ settimane; 20% Test, $N_{test} = 21$ settimane). Sono stati messi a confronto tre approcci metodologici distinti, i cui forecast sul test set sono riportati in Figura 1.19:

1. **Modello A (ARIMA(2, 1, 1) Baseline):** Rappresenta l'approccio univariato ottimizzato basato unicamente sullo storico della variabile endogena.
2. **Modello B (SARIMA(2,1,0) × (1,1,0)₅₂):** Struttura introdotta per forzare analiticamente una differenziazione regolare e una differenziazione stagionale rigida a lag 52.
3. **Modello C (SARIMAX(2,1,1) con Variabili Esogene):** Configurazione multivariata che integra i livelli di $PM_{2.5}$ e della temperature come regressori esterni standardizzati, inseriti con un ritardo temporale pari a 1 settimana (*Lag 1*) per evitare data leakage e simulare una latenza di risposta epidemiologica.




Figura 1.19: Confronto grafico sul test set tra i ricoveri reali osservati e le traiettorie predittive dei modelli A, B e C.

Per stabilire un criterio quantitativo di accuratezza, i modelli sono stati valutati sul test set mediante le metriche di Mean Absolute Error (MAE), Root Mean Squared Error (RMSE) e il coefficiente di determinazione (R^2), riassunte nella Tabella 1.1.

Tabella 1.1: Tabella comparativa delle metriche di performance sul test set.

Modello Predittivo	MAE	RMSE	R^2
Modello A: SARIMA(2,1,1) $\times$ (0,0,0) ₅₂	18.76	24.54	−0.000
Modello B: SARIMA(2,1,0) $\times$ (1,1,0) ₅₂	26.81	33.42	−0.855
Modello C: SARIMAX con Esogene (Lag 1)	18.56	24.80	−0.021

L’analisi comparativa dei risultati numerici e l’ispezione visiva delle traiettorie predittive delineano dinamiche di fondamentale rilevanza:

- Il **Modello A** manifesta il limite strutturale intrinseco dei processi univariati a memoria corta: la funzione di forecast decade rapidamente appiattendosi sul valore medio storico della serie differenziata, registrando $R^2 = -0.000$. Tale comportamento è matematicamente atteso per un processo ARIMA(2,1,1) senza componente stagionale: in assenza di segnali periodici forti, le previsioni convergono rapidamente verso la media.
- Il **Modello B** fallisce la validazione empirica per due ragioni concorrenti. In primo luogo, il modello non converge (std err sigma2 = 4876.5), rendendo inaffidabili tutti i parametri stimati. In secondo luogo, la forzatura dell’operatore di differenziazione stagionale ($D = 1$) su una serie priva di una reale ciclicità rigida a 52 settimane introduce una forte distorsione matematica, portando a MAE = 26.81 e $R^2 = -0.855$.
- Il **Modello C (SARIMAX)** ottiene il MAE marginalmente inferiore (18.56 vs 18.76 del Modello A), tuttavia la differenza è trascurabile e non costituisce un miglioramento operativo rilevante. Crucialmente, entrambe le variabili esogene risultano statisticamente non significative nel modello stimato: PM2.5 ($p = 0.621$) e temperatura ($p = 0.529$). Questo risultato è pienamente coerente con quanto emerso dall’EDA, dove tutte le correlazioni di Pearson tra variabili ambientali e ricoveri erano risultate non significative ($|r| < 0.08$, $p > 0.44$ per tutte le variabili). Il coefficiente $R^2 = -0.021$ conferma che il Modello C non apporta capacità predittiva aggiuntiva rispetto alla sola media storica.

In conclusione, nessuno dei tre modelli riesce a spiegare la varianza della serie dei ricoveri in modo sostanziale. Questo risultato è metodologicamente coerente con la natura sintetica del dataset, generato senza una struttura causale lineare reale tra inquinanti atmosferici e ricoveri: in assenza di un segnale epidemiologico genuino nelle variabili esogene, la modellazione SARIMAX non può produrre un miglioramento rispetto alla baseline univariata. Il valore metodologico dello studio risiede nell’aver dimostrato rigorosamente questa indipendenza attraverso l’intera pipeline analitica EDA $\rightarrow$ correlazione $\rightarrow$ CCF $\rightarrow$ modellazione comparativa.

1.5.6 Forecasting Futuro Fuori Campione

L’ultima fase dello studio prevede la generazione delle traiettorie di *forecasting* futuro fuori campione per un orizzonte temporale esteso alle successive **4 settimane** (corrispondenti al mese di gennaio 2022), spingendo le proiezioni oltre l’ultimo dato storico osservato (2 gennaio 2022). Il confronto visivo tra le risposte dinamiche dei tre modelli analizzati è illustrato in Figura 1.20.




Figura 1.20: Proiezioni di forecasting futuro fuori campione (orizzonte a 4 settimane, 9–30 gennaio 2022) per i modelli univariati e multivariati.

Le proiezioni puntuali per le 4 settimane successive sono: Modello A: 62, 60, 52, 53 ricoveri settimanali; Modello C: 61, 60, 52, 53 ricoveri settimanali. I due modelli producono traiettorie pressoché identiche, confermando che le esogene non aggiungono informazione predittiva reale. Modello B: 106, 48, 65, 69 ricoveri, con oscillazioni artificiali legate alla non-convergenza.

L'analisi visiva delle traiettorie future evidenzia in modo nitido le differenze matematiche intrinseche alle tre strutture:

- **Modello A (ARIMA(2,1,1) — Linea Arancione):** Il forecast futuro decade asintoticamente verso il valore medio di lungo periodo della serie storica. Nel giro di pochi lag la componente predittiva si stabilizza su una traiettoria piatta, fungendo da baseline conservativa di breve termine.
- **Modello B (SARIMA Forzato — Linea Rossa):** La traiettoria futura genera oscillazioni artificiali e instabili, ereditate dalla non-convergenza e dall'over-differencing stagionale. L'utilizzo operativo di questo modello è sconsigliato a causa dell'elevato rischio di falsi allarmi sanitari.
- **Modello C (SARIMAX con Variabili Esogene — Linea Viola):** Produce traiettorie quasi identiche al Modello A, confermando che in assenza di un segnale causale reale nelle esogene, il modello multivariato collassa sul comportamento univariato. Le variabili esogene future sono simulate tramite i valori medi del test set come proxy prudenziale (scenario medio).

Nota Operativa e Limitazioni Gestionali: In sede di implementazione ingegneristica e ospedaliera, è fondamentale evidenziare che i risultati di questo studio, condotto su dati sintetici privi di una struttura causale reale tra inquinanti e ricoveri, non sono direttamente trasferibili a un contesto operativo reale. Su dati epidemiologici empirici, dove tale struttura causale esiste, il Modello C (SARIMAX) andrebbe accoppiato con le pipeline di previsione meteorologica e di dispersione della qualità dell'aria a breve e medio termine, consentendo una programmazione flessibile ed efficiente dei posti letto e dei turni del personale medico in concomitanza con le ondate di inquinamento atmosferico.